

# Rachunek Prawdopodobieństwa I

Data ostatniej aktualizacji: 30 czerwca 2024

## 1 Krótki Wstęp

Uważny czytelnik zauważy też że poniższe notatki przypominają niezwykle dydaktyczne prace dr Arkadiusza Męcla, które również gorąco polecam.

*Link do omówienia pewniaków na egzamin znajduje się [tutaj](#)*

## 2 Aksjomatyka Rachunku Prawdopodobieństwa

### Definicja 1: Przestrzeń Propabilistyczna

PRZESTRZENIĄ PROPABILISTYCZNĄ nazywamy trójkę  $(\Omega, \mathcal{F}, P)$ , gdzie:

- $\Omega$  - zbiór (nazywany zbiorem zdarzeń elementarnych),
- $\mathcal{F}$  -  $\sigma$ -ciało podzbiorów  $\Omega$ ,
- $P$  - nieujemna miara na  $\mathcal{F}$  taka, że  $P(\Omega) = 1$ .

Miarę  $P$  nazywamy prawdopodobieństwem lub miarą probabilistyczną.

### Definicja 2: $\sigma$ -ciało zbiorów

$\mathcal{F}$  jest  $\sigma$ -CIAŁEM PODZBIORÓW  $\Omega$  jeżeli:

- $\Omega \in \mathcal{F}$ ,
- $A \in \mathcal{F} \Rightarrow A^C := \Omega \setminus A \in \mathcal{F}$ ,
- $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$ .

### Definicja 3: Aksjomaty prawdopodobieństwa (Kołmogorowa)

- $\forall_{A \in \mathcal{F}} P(A) \geq 0$ ,
- $P(\Omega) = 1$ ,
- $A_1, A_2, \dots \in \mathcal{F}$  oraz  $A_i \cap A_j = \emptyset$ , dla  $i \neq j \Rightarrow P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$ .

### Definicja 4

Przyjmujemy następującą terminologię:

- Zbiór  $\Omega$  to zbiór zdarzeń elementarnych (podstawowych możliwych wyników eksperymentu, oznaczanych  $\omega \in \Omega$ ),

- Elementy  $\mathcal{F}$  to zdarzenia,
- Dla  $A \in \mathcal{F}$ , elementy  $A$  to zdarzenia sprzyjające  $A$ ,
- Zdarzenie  $A^C$  to zdarzenie przeciwne,
- Zdarzenie  $\emptyset$  to zdarzenie niemożliwe,
- Zdarzenie  $\Omega$  to zdarzenie pewne.

### Twierdzenie 1: Własności prawdopodobieństwa

Poniżej zakładamy, że wszystkie rozważane zbiory należą do  $\mathcal{F}$ .

1.  $\mathbb{P}(\emptyset) = 0$ ,
2.  $\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i)$  o ile  $A_i \cap A_j = \emptyset$  dla  $i \neq j$ ,
3.  $0 \leq \mathbb{P}(A) \leq 1$ ,
4.  $A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$ ,
5.  $\mathbb{P}(A^C) = 1 - \mathbb{P}(A)$ ,
6.  $\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i)$  dla  $n < \infty$ .

### Twierdzenie 2: Twierdzenie o Ciągłości

Niech  $(\Omega, \mathcal{F}, \mathbb{P})$  będzie przestrzenią probabilistyczną oraz  $A_i \in \mathcal{F}$  dla  $i = 1, 2, \dots$

1. Jeżeli  $A_1 \subseteq A_2 \subseteq \dots$  (mówimy, że  $A_i$  są wstępujące, ozn.  $A_i \nearrow A$ ) oraz  $A = \bigcup_{i=1}^{\infty} A_i$ , to  $\mathbb{P}(A) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$ .
2. Jeżeli  $A_1 \supseteq A_2 \supseteq \dots$  (mówimy, że  $A_i$  są zstępujące, ozn.  $A_i \searrow A$ ) oraz  $A = \bigcap_{i=1}^{\infty} A_i$ , to  $\mathbb{P}(A) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$ .

### Definicja 5: Prawdopodobieństwo warunkowe

Niech  $(\Omega, \mathcal{F}, \mathbb{P})$  będzie przestrzenią probabilistyczną, zaś  $B \in \mathcal{F}$  zdarzeniem takim, że  $\mathbb{P}(B) > 0$ . PRAWDOPODOBIENSTWEM WARUNKOWYM POD WARUNKIEM  $B$  nazywamy funkcję  $\mathbb{P}(\cdot|B) : \mathcal{F} \rightarrow [0, 1]$  określoną dla  $A \in \mathcal{F}$  wzorem

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

### Twierdzenie 3

Jeśli zdarzenia  $A_1, \dots, A_n$  spełniają  $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) > 0$ , to

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2|A_1) \cdot \mathbb{P}(A_3|A_1 \cap A_2) \cdots \mathbb{P}(A_n|A_1 \cap \dots \cap A_{n-1}).$$

#### Twierdzenie 4

Jeżeli  $\{H_i\}_{i \in I}$  jest przeliczalnym rozbiem  $\Omega$  takim, że dla każdego  $i \in I$  mamy  $P(H_i) > 0$ , to dla dowolnego  $A \in \mathcal{F}$  zachodzi:

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(H_i) \cdot \mathbb{P}(A|H_i).$$

#### Definicja 6: Zdarzenia niezależne

Zdarzenia  $A$  i  $B$  nazwiemy NIEZALEŻNYMI, jeśli  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ .

#### Definicja 7: Niezależne $\sigma$ -ciała

$\sigma$ -ciała  $\mathcal{G}_1$  i  $\mathcal{G}_2 \subseteq \mathcal{F}$  nazwiemy NIEZALEŻNYMI, jeśli dla każdego  $A \in \mathcal{G}_1$  i  $B \in \mathcal{G}_2$  zachodzi  $\forall A \in \mathcal{G}_1 \forall B \in \mathcal{G}_2 \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ .

#### Definicja 8: $\pi$ -układ

Rodzinę  $\mathcal{A}$  podzbiorów  $\Omega$  nazwiemy  $\pi$ -UKŁADEM (lub rodziną multiplikatywną), jeżeli dla każdych  $A, B \in \mathcal{A}$  zachodzi  $A \cap B \in \mathcal{A}$ .

#### Definicja 9: $\lambda$ -układ

Rodzinę  $\mathcal{G}$  podzbiorów  $\Omega$  nazwiemy  $\lambda$ -UKŁADEM, jeżeli

1.  $\Omega \in \mathcal{G}$ ,
2.  $\forall A, B \in \mathcal{G}, A \subseteq B \Rightarrow B \setminus A \in \mathcal{G}$ ,
3.  $\forall A_1, A_2, \dots \in \mathcal{G}, A_n \nearrow A \Rightarrow A \in \mathcal{G}$ .

#### Twierdzenie 5: Lemat o $\pi$ - $\lambda$ układach (o rodzinie multiplikatywnej)

Niech  $\mathcal{A}$  będzie  $\pi$ -układem podzbiorów  $\Omega$ , zaś  $\mathcal{G}$  to  $\lambda$ -układ taki, że  $\mathcal{A} \subseteq \mathcal{G}$ . Wówczas  $\sigma(\mathcal{A}) \subseteq \mathcal{G}$ .

#### Twierdzenie 6

Niech  $\Omega$  - dowolny zbiór,  $\mathcal{A} \subset 2^\Omega$  będzie  $\pi$ -układem,  $\mathcal{F} = \sigma(\mathcal{A})$ ,  $\mathbb{P}, \mathbb{Q}$  - miary probabilistyczne, t. że

$$\forall_{A \in \mathcal{A}} \mathbb{P}(A) = \mathbb{Q}(A)$$

to wtedy

$$\forall_{B \in \mathcal{F}} \mathbb{P}(B) = \mathbb{Q}(B)$$

### Twierdzenie 7

Niech  $\Omega_i, \mathcal{F}_i, \mathbb{P}_i, i = 1, \dots, n$  będą przestrzeniami probabilistycznymi. Możemy zdefiniować:

$$\Omega = \Omega_1 \times \dots \times \Omega_n,$$

$$\mathcal{F} = \mathcal{F}_1 \otimes \dots \otimes \mathcal{F}_n = \sigma(A_1 \times \dots \times A_n | A_1 \in \mathcal{F}_1, \dots, A_n \in \mathcal{F}_n).$$

Wówczas  $\mathbb{P} = \mathbb{P}_1 \otimes \dots \otimes \mathbb{P}_n$  jest jedyną taką miarą na  $\mathcal{F}$ , że zachodzi

$$\forall A_1 \in \mathcal{F}_1, \dots, A_n \in \mathcal{F}_n \quad \mathbb{P}(A_1 \times \dots \times A_n) = \mathbb{P}_1(A_1) \cdot \dots \cdot \mathbb{P}_n(A_n).$$

### Twierdzenie 8

Niech  $(\mathcal{A}_i) \in \mathcal{F}$  niezależne  $\pi$ -układy, takie że

$$\forall_{A_i \in \mathcal{A}_i} \mathbb{P}(A_1 \cap \dots \cap A_n) = \prod_{i=1}^n \mathbb{P}(A_i)$$

Wtedy  $\sigma(A_1), \dots, \sigma(A_n)$  niezależne

### Twierdzenie 9: Twierdzenie 0-1 (Twierdzenie Kołmogorowa)

Niech  $G_1, G_2, \dots$   $\sigma$ -ciała niezależne

$$G_R = \bigcap_{i=1}^{\infty} \sigma(G_i, G_{i+1}, \dots)$$

Wtedy

$$\forall_{B \in G_R} \mathbb{P}(B) = 0 \text{ albo } \mathbb{P}(B) = 1$$

*Prostym wnioskiem z tego twierdzenia jest to, że jeśli  $A_i$  są niezależne, to  $\mathbb{P}(\limsup A_n) \in \{0, 1\}$*

### Twierdzenie 10: Lemat Borela-Cantellego

Niech  $(\Omega, \mathcal{F}, \mathbb{P})$  będzie przestrzenią probabilistyczną,  $A_1, A_2, \dots \in \mathcal{F}$ . Wówczas:

1. Jeśli  $\sum_{i=1}^{\infty} \mathbb{P}(A_i) < \infty$ , to prawdopodobieństwo zajścia nieskończenie wielu spośród zdarzeń  $A_i$  wynosi 0.
2. Jeśli  $A_i$  są niezależne oraz  $\sum_{i=1}^{\infty} \mathbb{P}(A_i) = \infty$ , to  $\mathbb{P}(\limsup A_n) = 1$ , to prawdopodobieństwo zajścia nieskończenie wielu spośród zdarzeń  $A_i$  wynosi 1.

### Definicja 10: Przestrzeń stanów

Parę  $(E, \mathcal{B})$ , gdzie  $E$  to zbiór, a  $\mathcal{B}$  to  $\sigma$ -ciało jego podzbiorów, nazywamy przestrzenią stanów.

### Definicja 11: Zmienna losowa

Zmienną losową o wartościach w przestrzeni stanów  $(E, \mathcal{B})$  nazywamy dowolną funkcję mierzalną  $X : (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{B})$ .

Równoważnie:

$X : \Omega \rightarrow \mathbb{R}$  jest zmienną losową wtedy i tylko wtedy, gdy dla każdego  $a \in \mathbb{R}$   $\{X \neq a\} = X^{-1}((-\infty, a]) \in \mathcal{F}$ .

### Twierdzenie 11

Jeżeli  $\mathcal{A}$  to dowolna rodzina podzbiorów  $E$ , taka że  $\sigma(\mathcal{A}) = \mathcal{B}$ , to dla każdego  $X : \Omega \rightarrow E$  zachodzi

$$X \text{ jest zmienną losową} \Leftrightarrow \forall_{A \in \mathcal{A}} X^{-1}(A) \in \mathcal{F}.$$

Wynikają z tego następujące wnioski:

1.  $X : \Omega \rightarrow \mathbb{R}$  jest zmienną losową wtedy i tylko wtedy, gdy dla każdego  $a \in \mathbb{R}$   $\{X \neq a\} = X^{-1}((-\infty, a]) \in \mathcal{F}$ .
2.  $X : \Omega \rightarrow \mathbb{R}^n$  jest wektorem losowym wtedy i tylko wtedy, gdy  $X_1, \dots, X_n$  są rzeczywistymi zmiennymi losowymi.

### Twierdzenie 12

Jeżeli  $X : \Omega \rightarrow \mathbb{R}^n$  to wektor losowy, zaś  $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$  to funkcja borelowska, to  $\phi(X)$  jest wektorem losowym.

### Definicja 12: Rozkład zmiennej losowej

Rozkład zmiennej losowej  $X : \Omega \rightarrow (E, \mathcal{B})$  to miara probabilistyczna  $\mu_X$  na  $(E, \mathcal{B})$  dana wzorem

$$\mu_X(A) = P(X \in A) = P(\{\omega \in \Omega : X(\omega) \in A\}), \quad \text{dla } A \in \mathcal{B}.$$

### Definicja 13: Rozkład Dyskretny

Rozkład  $\mu$  nazywamy dyskretnym jeżeli istnieje zbiór przeliczalny  $S \subseteq \mathbb{R}^n$  taki, że  $\mu(S) = 1$ .

### Definicja 14: Rozkłady Dyskretne - przykłady

1. ROZKŁAD SKUPIONY W PUNKCIE (delta Diraca):

$$\delta_a(A) = \begin{cases} 1, & \text{jeśli } a \in A, \\ 0, & \text{jeśli } a \notin A. \end{cases}$$

Jest to rozkład zmiennej  $X$  takiej, że  $\mathbb{P}(X = a) = 1$ .

2. ROZKŁAD BERNOULLIEGO z parametrami  $n \geq 0$ ,  $p \in [0, 1]$ :

$$\mu = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} \delta_k.$$

Jest to rozkład zmiennej  $X$  takiej, że  $\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \delta_k$  dla  $k = 0, 1, \dots$ .

3. ROZKŁAD POISSONA z parametrem  $\lambda > 0$ :

$$p_s = \frac{\lambda^s}{s!} e^{-\lambda}, \quad S = \{0, 1, 2, \dots\}.$$

### Definicja 15: Rozkład ciągły i Gęstość rozkładu

Rozkład prawdopodobieństwa  $\mu$  na  $\mathbb{R}^n$  nazwiemy CIĄGŁYM jeżeli istnieje funkcja borelowska

$f : \mathbb{R}^n \rightarrow \mathbb{R}$  taka, że

$$\forall_{A \in \mathcal{B}(\mathbb{R}^n)} \mu(A) = \int_A f(x) dx$$

Funkcję  $f$  nazywamy GĘSTOŚCIĄ. Jeżeli  $X$  jest wektorem losowym i  $\mu_X$  jest rozkładem ciągłym o gęstości  $f$ , to mówimy też, że  $f$  jest gęstością  $X$ . Oznacza to, że

$$\mathbb{P}(X \in A) = \int_A f(x) dx$$

Czasami stosowane jest oznaczenie  $f(x) = \frac{d\mu(x)}{dx}$ .

**Własności gęstości:**

1.  $\int_{\mathbb{R}^n} f(x) dx = 1$ .
2.  $f = 0$  prawie wszędzie, tzn.  $\lambda^n(\{x \in \mathbb{R}^n | f(x) < 0\}) = 0$ .
3. Funkcja  $f$  jest wyznaczona jednoznacznie z dokładnością do zbioru miary zero.

### Definicja 16: Rozkłady Ciągłe - Przykłady

1. ROZKŁAD JEDNOSTAJNY na zbiorze  $A \subseteq \mathbb{R}^n$ . Załóżmy, że  $A \in \mathcal{B}(\mathbb{R}^n)$  oraz  $0 < \lambda(A) < \infty$ . Wówczas funkcja

$$g(x) = \frac{\mathbf{1}_A(x)}{\lambda(A)}$$

jest gęstością prawdopodobieństwa.

2. ROZKŁAD WYKŁADNICZY z parametrem  $\lambda > 0$  to rozkład o gęstości

$$g(x) = \lambda e^{-\lambda x} \cdot \mathbf{1}_{\mathbb{R}^+}(x).$$

Ten rozkład oznaczamy  $\text{Exp}(\lambda)$ .

3. ROZKŁAD GAUSSOWSKI/NORMALNY z parametrami  $a, \sigma^2$ , oznaczany  $N(a, \sigma^2)$  (gdzie  $a$  - wartość oczekiwana/wektor średni, a  $\sigma^2$  - wariancja/macierz kowariancji) to rozkład o gęstości

$$g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-a)^2}{2\sigma^2}\right).$$

Na  $\mathbb{R}^d$ ,  $a \in \mathbb{R}^d$ ,  $Q$  macierz  $d \times d$  dodatnio określona, gęstość ma postać:

$$g(x) = \frac{1}{(\sqrt{2\pi})^d \sqrt{\det Q}} \exp\left(-\frac{1}{2}(x-a)^T Q^{-1}(x-a)\right), \quad x \in \mathbb{R}^d$$

4. ROZKŁAD GAMMA  $\Gamma(r, \lambda)$ ,  $r > 0$ ,  $\lambda > 0$ .

Gęstość:

$$g(x) = \frac{1}{\Gamma(r)\lambda^r} x^{r-1} e^{-\lambda x} \mathbf{1}_{(0,\infty)}(x),$$

gdzie  $\Gamma$  oznacza funkcję Gamma Eulera:  $\Gamma(r) = \int_0^\infty x^{r-1} e^{-x} dx$ .

W szczególności,

$$g(x) = \frac{\mathbf{1}_{(a,b)}(x)}{b-a}$$

zadaje rozkład jednostajny na odcinku  $(a, b)$

### Przykład 1: Egzamin poprawkowy 2009

Pomimo użycia wartości oczekiwanej i wariancji, kluczem do tego zadania jest znajomość własności rozkładu normalnego, dlatego dałem je tutaj

**Zadanie 1.** Niech  $X, Y$  - niezależne zmienne losowe,  $X, Y \sim N(0, 1)$

- a) znaleźć gęstość  $X + 2Y + 1$
- b) znaleźć gęstość  $(X + Y, X + 2Y)$

#### Rozwiązanie Zadania 1.

- a) Przypomnijmy, że liniowy obraz  $(X, Y)$ , gdzie  $X$  i  $Y$  mają rozkład normalny, ma rozkład normalny, więc

$$\mathbb{E}X + 2Y + 1 = \mathbb{E}X + 2\mathbb{E}Y + \mathbb{E}1 = 0 + 2 \cdot 0 + 1 = 1$$

$$\text{Var}(X + 2Y + 1) = \text{Var}(X + 2Y) = \text{Var}X + \text{Var}2Y = \text{Var}X + 2^2 \cdot \text{Var}Y = 1 + 4 \cdot 1 = 5$$

Alternatywnie, możemy znaleźć parametry poprzez własności rozkładu normalnego  $X + 2Y + 1$ :

$$\begin{aligned} X &\sim N(0, 1) & Y &\sim N(0, 1) \\ X &\sim N(0, 1) & 2Y &\sim N(2 \cdot 0, 2^2 \cdot 1) = N(0, 4) \\ X &\sim N(0, 1) & 2Y + 1 &\sim N(0 + 1, 4) = N(1, 4) \\ X + 2Y + 1 &\sim N(0 + 1, 1 + 4) = N(1, 5) \end{aligned}$$

Tak czy siak, otrzymujemy

$$g_{X+2Y+1}(z) = \frac{1}{\sqrt{2\pi \cdot 5}} \exp\left(-\frac{(x-1)^2}{2 \cdot 5}\right)$$

- b) Korzystamy z przypadku wielowymiarowego. Ponieważ  $X, Y$  - niezależne, łatwo liczymy

$$\mathbb{E}(X + Y) = \mathbb{E}X + \mathbb{E}Y = 0 + 0 = 0 \quad \mathbb{E}(X + 2Y) = 0 \implies a = [0, 0]$$

$$\text{Var}(X + Y) = \text{Var}X + \text{Var}Y = 1 + 1 = 2$$

$$\text{Var}(X + 2Y) = \text{Var}X + 4\text{Var}(Y) = 5$$

$$\begin{aligned} \text{Cov}(X + Y, X + 2Y) &= \text{Cov}(X, X + 2Y) + \text{Cov}(Y, X + 2Y) = \\ &= \text{Cov}(X, X) + \text{Cov}(X, 2Y) + \text{Cov}(Y, X) + \text{Cov}(Y, 2Y) = \text{Var}X + 0 + 0 + 2\text{Var}Y = \\ &= 1 + 2 \cdot 1 = 3 \end{aligned}$$

Mamy więc że

$$\begin{aligned} Q &= \begin{bmatrix} \text{Var}(X + Y) & \text{Cov}(X + Y, X + 2Y) \\ \text{Cov}(X + Y, X + 2Y) & \text{Var}(X + 2Y) \end{bmatrix} \\ Q &= \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix} \implies Q^{-1} = \begin{bmatrix} 5 & -3 \\ -3 & 2 \end{bmatrix}, \det Q = 1 \end{aligned}$$

Podstawiamy do wzoru:

$$\begin{aligned} g_{(X+Y, X+2Y)}(x, y) &= \frac{1}{(\sqrt{2\pi})^d \sqrt{\det Q}} \exp\left(-\frac{1}{2}((x, y) - a)^T Q^{-1}((x, y) - a)\right) = \\ &= \frac{1}{2\pi} \exp\left(-\frac{1}{2}(5x^2 - 6xy + 2y^2)\right) \end{aligned}$$

### Twierdzenie 13

Jeżeli  $X_1, \dots, X_n$  są zmiennymi losowymi, to następujące warunki są równoważne:

1.  $X_1, \dots, X_n$  są niezależne,
2.  $\mu(X_1, \dots, X_n) = \mu_{X_1} \otimes \dots \otimes \mu_{X_n}$ ,
3. Dla każdego  $t_1, \dots, t_n \in \mathbb{R}$  zachodzi

$$F_{X_1, \dots, X_n}(t_1, \dots, t_n) = F_{X_1}(t_1) \cdot \dots \cdot F_{X_n}(t_n)$$

### Definicja 17: Dystrybuanta

Dystrybuantą wektora losowego  $X = (X_1, \dots, X_n)$  o wartościach w  $\mathbb{R}^n$  nazywamy funkcję  $F_X : \mathbb{R}^n \rightarrow [0, 1]$ , daną wzorem

$$F_X(t_1, \dots, t_n) = \mathbb{P}(X_1 \leq t_1, X_2 \leq t_2, \dots, X_n \leq t_n).$$

W szczególności dystrybuantą zmiennej losowej  $X$  jest funkcja  $F_X : \mathbb{R} \rightarrow [0, 1]$  dana wzorem  $F_X(t) = \mathbb{P}(X \leq t)$ . Uwaga: W starszych podręcznikach czasami definiuje się  $F_X(t) = \mathbb{P}(X < t)$ .

### Twierdzenie 14

Jeżeli  $X$  i  $Y$  to  $n$ -wymiarowe wektory losowe, to

$$F_X = F_Y \iff \mu_X = \mu_Y.$$

Uwaga:  $X$  i  $Y$  nie muszą być określone na tej samej przestrzeni probabilistycznej.

### Twierdzenie 15: Własności dystrybuanty zmiennej losowej

Niech  $X : \Omega \rightarrow \mathbb{R}$  będzie zmienną losową, zaś  $F = F_X$  jej dystrybuantą. Wówczas:

1. Dla każdego  $t \in \mathbb{R}$ ,  $F(t) \in [0, 1]$ ,
2.  $F$  jest niemalejąca,
3.  $F$  jest prawostronnie ciągła: Dla każdego  $t_0 \in \mathbb{R}$ ,  $\lim_{t \rightarrow t_0^+} F(t) = F(t_0)$ ,
4.  $\lim_{t \rightarrow \infty} F(t) = 1$  oraz  $\lim_{t \rightarrow -\infty} F(t) = 0$ .

### Twierdzenie 16

Jeżeli  $F$  jest dystrybuantą zmiennej losowej  $X$ ,  $F'$  istnieje prawie wszędzie oraz

$$\int_{\mathbb{R}} F'(x) dx = 1,$$

to  $F'$  jest gęstością zmiennej losowej  $X$ .



**Twierdzenie 17**

Jeśli  $X$  jest zmienną losową o wartościach w  $\mathbb{R}^d$  o gęstości  $g_X$ , zaś  $\varphi : \mathbb{R}^d \rightarrow \mathbb{R}^d$  jest funkcją klasy  $C^1$  i różnowartościową, to  $\varphi(X)$  ma gęstość daną wzorem

$$g_{\varphi(X)}(x) = \mathbf{1}_{\text{Im}\varphi(x)} \cdot g_X(\varphi^{-1}(x)) \cdot \left| \det D\varphi^{-1}(x) \right|$$

**Definicja 18: Rozkłady Brzegowe**

Jeśli  $X = (X_1, \dots, X_n)$  jest wektorem losowym o wartościach w  $\mathbb{R}^n$  o rozkładzie  $\mu$ , to rozkłady zmiennych losowych  $X_1, X_2, \dots, X_n$ , tj.

$$\mu_{X_i}(A) = \mu(\mathbb{R} \times \dots \times \mathbb{R} \times A \times \mathbb{R} \times \dots \times \mathbb{R}) \quad \text{dla } A \in \mathcal{B}(\mathbb{R}) \text{ na } i\text{-tym miejscu}$$

nazywamy ROZKŁADAMI BRZEGOWYMI. Na odwrót, rozkład wektora  $X$  nazywamy rozkładem łącznym zmiennych  $X_1, \dots, X_n$ .

**Twierdzenie 18**

Jeśli rozkład wektora losowego  $X = (X_1, \dots, X_n)$  ma gęstość  $g$ , to rozkłady brzegowe również mają gęstości wyrażone wzorami:

$$g_{X_i}(x_i) = \int_{\mathbb{R}^{n-1}} g(x_1, \dots, x_d) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n.$$

**Definicja 19: Niezależne wektory losowe**

Wektory losowe  $X_1, \dots, X_n : \Omega \rightarrow \mathbb{R}^m$  nazwiemy NIEZALEŻNYMI jeżeli  $\sigma$ -ciała  $\sigma(X_1), \dots, \sigma(X_n)$  są niezależne.

*Mówimy tu o niezależności łącznej. Istnieją zmienne losowe parami niezależne, które nie są niezależne łącznie*

**Twierdzenie 19**

Niech  $X_1, \dots, X_n$  będą zmiennymi o rozkładach dyskretnych skupionymi odpowiednio na zbiorach  $S_{X_1}, \dots, S_{X_n}$  (tzn.  $\mathbb{P}(X_i \in S_{X_i}) = 1$ ). Wówczas

$$\forall_{s_1, \dots, s_n \in S}$$

$$X_1, \dots, X_n \text{ są niezależne} \iff \mathbb{P}(X_1 = s_1, \mathbb{P}(X_2 = s_2), \dots, X_n = s_n) = \prod_{k=1}^n \mathbb{P}(X_k = s_k)$$

**Twierdzenie 20**

Niech  $X_1, \dots, X_n$  będą zmiennymi losowymi o rozkładach ciągłych z gęstościami odpowiednio  $g_1, g_2, \dots, g_n$ . Wtedy i tylko wtedy, gdy rozkład łączny ma gęstość  $g_X$  spełniającą:

$$g_X(x_1, \dots, x_n) = g_1(x_1) \cdot \dots \cdot g_n(x_n)$$

### Definicja 20: Wartość oczekiwana

Niech  $X$  będzie zmienną losową o wartościach rzeczywistych, określoną na pewnej przestrzeni probabilistycznej  $\Omega, \mathcal{F}, \mathbb{P}$ . Mówimy, że  $X$  ma wartość oczekiwaną jeżeli

$$\int_{\Omega} |X(\omega)| \mathbb{P}(d\omega) < \infty.$$

Wtedy wartością oczekiwaną (albo wartością średnią) zmiennej losowej  $X$  nazywamy liczbę

$$\mathbb{E}X := \int_{\Omega} X(\omega) \mathbb{P}(d\omega)$$

#### Własności:

1. Jeśli  $X$  i  $Y$  mają wartości oczekiwane, to dla dowolnych  $\alpha, \beta \in \mathbb{R}$  wartość oczekiwana  $\mathbb{E}(\alpha X + \beta Y)$  istnieje oraz  $\mathbb{E}(\alpha X + \beta Y) = \alpha \mathbb{E}X + \beta \mathbb{E}Y$ .
2. Jeśli  $X \geq 0$  prawie na pewno, to  $\mathbb{E}X \geq 0$ .
3. Jeśli  $\mathbb{E}|X| = 0$ , to  $X = 0$  prawie na pewno.
4.  $|\mathbb{E}X| \leq \mathbb{E}|X|$ .
5. Jeśli  $0 \leq X \leq Y$  prawie na pewno i  $\mathbb{E}Y$  istnieje, to istnieje również  $\mathbb{E}X$  oraz  $0 \leq \mathbb{E}X \leq \mathbb{E}Y$ .
6. Jeśli  $X$  i  $Y$  są niezależne, to  $\mathbb{E}XY = \mathbb{E}X\mathbb{E}Y$ .
7.  $\mathbb{E}|XY| \leq \sqrt{\mathbb{E}X^2 \mathbb{E}Y^2}$ .
8. Twierdzenie o zbieżności monotonicznej: Jeśli  $(X_n)$  jest ciągiem niemalejącym i  $X_n \geq 0$  prawie na pewno, to  $\mathbb{E} \lim_{n \rightarrow \infty} X_n = \lim_{n \rightarrow \infty} \mathbb{E}X_n$ .
9. **Lemat Fatou:** Jeśli  $X_n \geq 0$  prawie na pewno, to  $\mathbb{E} \liminf_{n \rightarrow \infty} X_n \leq \liminf_{n \rightarrow \infty} \mathbb{E}X_n$ .
10. **Twierdzenie Lebesgue'a o zbieżności zmajorizowanej:** Jeśli ciąg  $(X_n)$  jest taki, że  $|X_n| \leq Y$  prawie na pewno,  $\mathbb{E}Y < \infty$ , oraz istnieje granica  $X = \lim_{n \rightarrow \infty} X_n$  prawie na pewno, to  $X$  ma wartość oczekiwaną oraz  $\mathbb{E}X = \lim_{n \rightarrow \infty} \mathbb{E}X_n$ .
11. Niech  $X$  będzie zmienną losową o wartościach w przestrzeni mierzalnej  $(E, \mathcal{B})$  i niech  $\varphi : E \rightarrow \mathbb{R}$  będzie funkcją mierzalną z  $(E, \mathcal{B})$  w  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . Wtedy

$$\mathbb{E}\varphi(X) = \int_E \varphi(x) \mu(dx),$$

gdzie  $\mu$  oznacza rozkład  $X$ . Przy czym prawa strona równości jest dobrze określona wtedy i tylko wtedy, gdy lewa strona jest dobrze określona.

12.  $X$  jest zmienną losową o wartościach w  $(E, \mathcal{B})$ , a  $\varphi : E \rightarrow \mathbb{R}$  mierzalna względem odpowiednich  $\sigma$ -ciał, to

$$\mathbb{E}\varphi(X) = \sum_{k=1}^{\infty} \varphi(x_k) p_k,$$

o ile szereg jest zbieżny bezwzględnie.

13. Jeśli  $X$  jest wektorem losowym w  $\mathbb{R}^d$  o rozkładzie ciągłym z gęstością  $g$ , a  $\varphi : \mathbb{R}^d \rightarrow \mathbb{R}$  funkcją borelowską, to

$$\mathbb{E}\varphi(X) = \int_{\mathbb{R}^d} \varphi(x) g(x) dx,$$

o ile  $\int_{\mathbb{R}^d} |\varphi(x)| g(x) dx < \infty$ .

14. Jeśli  $X \geq 0$  prawie na pewno, to dla każdego  $p \geq 1$

$$\mathbb{E}X^p = \int_0^\infty pt^{p-1}\mathbb{P}(X > t) dt$$

15. Jeśli  $X$  jest zmienną losową o dystrybuancie  $F$ ,  $X \geq 0$  prawie na pewno, to

$$\mathbb{E}X = \int_0^\infty \mathbb{P}(X > t) dt = \int_0^\infty (1 - F(t)) dt$$

### Przykład 2: Egzamin 2023

**Zadanie 2.** Wektor losowy  $(X, Y)$  ma gęstość  $g(x, y) = Ce^{-x}y\mathbf{1}_{\{0 \leq y \leq x\}}$

a) wyznaczyć stałą  $C$

a) Obliczyć  $\mathbb{P}(2Y \leq X)$

a) Obliczyć  $\mathbb{E}((X + Y)^2|X)$

**Rozwiązanie Zadania 2.**

a) Chcemy skorzystać z tego że całka z gęstości wynosi 1. Liczymy całkę:

$$\int_{\mathbb{R}^2} g(x, y) =$$

Z warunku indykatora odczytujemy granice całkowania:

$$= \int_0^\infty \int_0^x Ce^{-x}y dy dx = \int_0^\infty Ce^{-x} \frac{x^2}{2} dx = \frac{C}{2} \int_0^\infty x^2 e^{-x} dx =$$

Następującą całkę możemy policzyć oczywiście przez części, możemy też zauważyć, że jest to funkcja gamma Eulera  $\Gamma(z) = \int_0^\infty t^{z-1}e^{-t} dt$ , a wiemy że dla  $z \in \mathbb{N}$ ,  $\Gamma(z+1) = z!$ .

Mamy więc

$$= \frac{C}{2} \Gamma(3) = \frac{C}{2} \cdot 2! = C \implies C = 1$$

b)

$$\mathbb{P}(2Y \leq X) = \mathbb{P}\left(Y \leq \frac{X}{2}\right) = \int_0^\infty e^{-x} \frac{x^2}{8} dx = \frac{1}{8} \int_0^\infty e^{-x} x^2 dx =$$

Zauważmy, że jest to ta sama całka co w podpunkcie a)

$$= \frac{1}{8} \cdot 2 = \frac{1}{4}$$

c) dokończyć

### Definicja 21: Wariancja

Niech  $X$  będzie zmienną losową rzeczywistą, taką że  $\mathbb{E}X$  istnieje. Wariancję  $X$  nazywamy wielkością

$$\text{Var } X = \mathbb{E}(X - \mathbb{E}X)^2,$$

o ile  $\mathbb{E}(X - \mathbb{E}X)^2 < \infty$ .

**Własności:**

1. Zmienna losowa  $X$  ma wariancję (skończoną), wtedy i tylko wtedy, gdy  $\mathbb{E}X^2 < \infty$ . Ponadto

$$\text{Var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2.$$

2.  $\text{Var}(aX) = a^2 \text{Var} X$ ,  $a \in \mathbb{R}$ ;
3.  $\text{Var} X \geq 0$ ;
4.  $\text{Var} X = 0 \Leftrightarrow X = \text{Const}$  p.n.;
5.  $\text{Var}(X + a) = \text{Var} X$ ,  $a \in \mathbb{R}$ .
6. Jeśli zmienne losowe  $X_1, \dots, X_n$  są niezależne o skończonej wariancji, to

$$\text{Var} \left( \sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var} X_i.$$

### Definicja 22: (Kowariancja i korelacja)

Niech  $X$  i  $Y$  będą zmiennymi losowymi o skończonej wariancji.

- a) Kowariancję  $X$  i  $Y$  nazywamy liczbą

$$\text{Cov}(X, Y) = \mathbb{E}(X - \mathbb{E}X)(Y - \mathbb{E}Y) = \mathbb{E}XY - \mathbb{E}X\mathbb{E}Y.$$

- b) Współczynnikiem korelacji zmiennych  $X$  i  $Y$  nazywamy

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var } X \text{Var } Y}}.$$

jeśli żadna ze zmiennych  $X$  i  $Y$  nie jest stała ( $\text{Var } X > 0$  i  $\text{Var } Y > 0$ ). W przeciwnym wypadku kładziemy  $\rho(X, Y) = 0$ .

### Przykład 3: Egzamin Zerowy 2024

**Zadanie 3.** Wektor losowy  $(X, Y)$  ma gęstość

$$g(x, y) = \begin{cases} Cye^{-x^2y} & \text{jeśli } x \geq 1, y \geq 0 \\ 0 & \text{w przeciwnym przypadku} \end{cases}$$

gdzie  $C$  jest pewną dodatnią stałą.

- a) Czy  $X$  i  $Y$  są niezależne?
- b) Obliczyć wartość oczekiwaną i wariancję zmiennej losowej  $X$
- c) Obliczyć kowariancję zmiennych  $X$  i  $Y$

**Rozwiązanie Zadania 3.**

Przypomnijmy, że

$$\text{Zmienne } X \text{ i } Y \text{ są niezależne} \iff g_X \cdot g_Y = g(x, y)$$

Łatwo zauważyć jednak że nie da się policzyć wzorów na gęstości brzegowe. Musimy więc kombinować, w tym celu znajdziemy najpierw  $C$ :

$$\int_{\mathbb{R}^2} g(x, y) = C \cdot \int_1^\infty \frac{1}{x^2} \int_0^\infty yx^2 e^{-x^2 y} dy dx =$$

Oczywiście możemy policzyć powyższą całkę przez części, możemy też zauważyć, że przekształciliśmy wewnętrzną całkę do postaci gdzie jest całką z gęstości rozkładu wykładniczego  $Exp(x^2)$ , czyli jest jego wartością oczekiwaną, z wiemy że  $\mathbb{E}Exp(\lambda) = \frac{1}{\lambda^2}$ . Otrzymujemy więc że

$$= C \cdot \int_1^\infty \frac{1}{x^4} dx = \frac{C}{3} \implies C = 3$$

Policzyliśmy  $C$ , pominiemy podpunkt a) i przejdźmy do podpunktu b)

b) Skorzystamy z tej samej sztuczki na poradzenie sobie z trudną całką

$$\begin{aligned} \mathbb{E}X &= \int_{\mathbb{R}^2} x \cdot g(x, y) = \int_1^\infty \int_0^\infty 3yx e^{-x^2 y} dy dx = 3 \cdot \int_1^\infty \frac{1}{x} \int_0^\infty yx^2 e^{-x^2 y} dy dx = \\ &= 3 \cdot \int_1^\infty \frac{1}{x^2} dx = \frac{3}{2} \end{aligned}$$

Do obliczenia wariancji potrzebujemy jeszcze  $\mathbb{E}X^2$

$$\mathbb{E}X^2 = \int_{\mathbb{R}^2} x^2 \cdot g(x, y) = \int_1^\infty \int_0^\infty 3yx^2 e^{-x^2 y} dy dx =$$

tutaj znowu sztuczka z wartością oczekiwaną rozkładu wykładniczego

$$= 3 \cdot \int_1^\infty \frac{1}{x^2} dx = 3$$

Otrzymujemy

$$\text{Var}X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = 3 - \frac{9}{4} = \frac{3}{4}$$

c) Przypomnijmy, że  $\text{Cov}(X, Y) = \mathbb{E}XY - \mathbb{E}X \cdot \mathbb{E}Y$ . Liczymy więc brakujące rzeczy

$$\begin{aligned} \mathbb{E}Y &= \int_{\mathbb{R}^2} y \cdot g(x, y) = \int_1^\infty \int_0^\infty 3y^2 e^{-x^2 y} dy dx = \int_1^\infty \frac{1}{x^2} \int_0^\infty 3x^2 y^2 e^{-x^2 y} dy dx = \\ &= 3 \cdot \int_1^\infty \frac{1}{x^2} \mathbb{E}(Exp(x^2))^2 dx = 3 \cdot \int_1^\infty \frac{1}{x^2} \cdot \frac{2}{x^4} dx = \frac{6}{5} \\ \mathbb{E}XY &= \int_{\mathbb{R}^2} xy \cdot g(x, y) = \int_1^\infty \int_0^\infty 3y^2 x e^{-x^2 y} dy dx = \int_1^\infty \frac{1}{x} \int_0^\infty 3y^2 x^2 e^{-x^2 y} dy dx = \\ &= 3 \cdot \int_1^\infty \frac{1}{x} \cdot \frac{2}{x^4} dx = \frac{3}{2} \end{aligned}$$

Tak więc

$$\text{Cov}(X, Y) = \frac{3}{2} - \frac{6}{5} \cdot \frac{3}{2} = -\frac{3}{10}$$

Wróćmy teraz do pozostawionego podpunktu a). Gdyby  $X$  i  $Y$  był niezależne, to  $\text{Cov}(X, Y) = 0$ . Widzimy jednak że tak nie jest, więc  $X$  i  $Y$  nie są niezależne.

### Definicja 23: (Macierz kowariancji)

Jeśli  $X = (X_1, \dots, X_d)$  jest wektorem losowym o wartościach w  $\mathbb{R}^d$ , przy czym zmienne losowe  $X_i$  mają skończoną wariancję, to macierz

$$(\text{Cov}(X_i, X_j))_{i,j=1}^d$$

nazywamy macierzą kowariancji wektora  $X$ .

### Twierdzenie 21: Wielowymiarowy rozkład Gaussa

Zmienne losowe  $X_1, \dots, X_d$  o łącznym rozkładzie Gaussa są niezależne wtedy i tylko wtedy, gdy są nieskorelowane.

### Twierdzenie 22: Nierówności związane z wartością oczekiwaną

1. **(Nierówność Höldera)** Niech  $X, Y$  będą zmiennymi losowymi,  $p, q \geq 1$ , takimi że  $\frac{1}{p} + \frac{1}{q} = 1$ , wtedy

$$\mathbb{E}|XY| \leq (\mathbb{E}|X|^p)^{\frac{1}{p}} (\mathbb{E}|Y|^q)^{\frac{1}{q}} = \|X\|_p \|Y\|_q.$$

2. **(Nierówność Jensena)** Niech  $X$  będzie zmienną losową, taką że  $\mathbb{E}|X| < \infty$  i niech  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  będzie funkcją wypukłą. Ponadto zakładamy, że  $\mathbb{E}|\varphi(X)| < \infty$ . Wtedy

$$\varphi(\mathbb{E}X) \leq \mathbb{E}\varphi(X).$$

3. **(Nierówność Minkowskiego)** Niech  $p \geq 1$ , wtedy

$$\|X + Y\|_p \leq \|X\|_p + \|Y\|_p.$$

4. **(Nierówność Markowa)** Jeśli  $X \geq 0$ ,  $\varepsilon > 0$ , to

$$\mathbb{P}(X \geq \varepsilon) \leq \frac{\mathbb{E}X}{\varepsilon}.$$

5. **(Nierówność Czebyszewa)** Jeśli  $X$  jest zmienną losową o skończonej wariancji, to dla każdego  $\varepsilon > 0$

$$\mathbb{P}(|X - \mathbb{E}X| \geq \varepsilon) \leq \frac{\text{Var } X}{\varepsilon^2}.$$

### Twierdzenie 23: Słabe prawo wielkich liczb

Niech  $X_1, X_2, \dots$  będą nieskorelowanymi zmiennymi losowymi o tym samym rozkładzie o skończonej wariancji. Oznaczmy  $S_n = \sum_{i=1}^n X_i$ . Wtedy dla każdego  $\varepsilon > 0$  zachodzi

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{S_n}{n} - \mathbb{E}X_1\right| > \varepsilon\right) = 0.$$

### Definicja 24: Rodzaje zbieżności

Niech  $X, X_1, X_2, \dots$  będą zmiennymi losowymi o wartościach w przestrzeni  $(E, \rho)$ , określonymi na tej samej przestrzeni probabilistycznej  $(\Omega, \mathcal{F}, \mathbb{P})$ . Mówimy, że

- ciąg  $X_n$  zbiega do  $X$  PRAWIE NA PEWNO przy  $n \rightarrow \infty$  (piszemy:  $X_n \xrightarrow{\text{p.n.}} X$ ), jeżeli

$$P\left(\left\{\omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) = 1;$$

- ciąg  $X_n$  zbiega do  $X$  WEDŁUG PRAWDOPODOBIENSTWA ( $X_n \xrightarrow{P} X$ ), jeżeli

$$\forall \varepsilon > 0 \lim_{n \rightarrow \infty} P(\rho(X_n, X) > \varepsilon) = 0;$$

- niech  $0 < p < \infty$ . Ciąg  $X_n$  zbiega do  $X$  WEDŁUG  $p$ -TEGO MOMENTU, jeżeli

$$\lim_{n \rightarrow \infty} E\rho(X_n, X)^p = 0.$$

Stosowane w zasadzie, gdy  $(E, \rho)$  jest przestrzenią Banacha i wtedy mówimy, że  $X_n$  zbiega do  $X$  w  $L^p$ , jeżeli  $E\|X_n\|^p < \infty$ ,  $E\|X\|^p < \infty$ , oraz  $\lim_{n \rightarrow \infty} E\|X_n - X\|^p = 0$ . Piszemy:  $X_n \xrightarrow{L^p} X$ .

Przy czym, jeżeli  $p \geq 1$ , to wystarczy zakładać, że  $E\|X_n\|^p < \infty$ . Jeżeli zachodzi  $\lim_{n \rightarrow \infty} E\|X_n - X\|^p = 0$ , to warunek  $E\|X\|^p < \infty$  jest automatycznie spełniony.

#### Twierdzenie 24

Następujące warunki są równoważne:

- $X_n \xrightarrow{\text{p.n.}} X$ ;
- $\forall \varepsilon > 0 \lim_{N \rightarrow \infty} P\left(\bigcap_{n=N}^{\infty} \{\rho(X_n, X) \leq \varepsilon\}\right) = 1$ ;
- $\forall \varepsilon > 0 \lim_{N \rightarrow \infty} P\left(\bigcup_{n=N}^{\infty} \{\rho(X_n, X) > \varepsilon\}\right) = 0$ .

#### Twierdzenie 25: Riesz

Niech  $X, X_1, X_2, \dots$  będą zmiennymi losowymi o wartościach w  $(E, \rho)$ . Jeżeli ciąg  $X_n$  zbiega według prawdopodobieństwa do  $X$  przy  $n \rightarrow \infty$ , to istnieje podciąg  $X_{n_k}$  taki, że  $X_{n_k}$  zbiega do  $X$  prawie na pewno, gdy  $k \rightarrow \infty$ .

#### Przykład 4: Zerówka 2023

**Zadanie 4.** Dwuwymiarowe wektory losowe  $(X_1, Y_1), (X_2, Y_2), \dots$  są niezależne i mają rozkład jednostajny na kole  $(0, 0)$  i promieniu 1 niech  $n = 1, 2, \dots$  i  $Z_n = \sqrt{X_n^2 + Y_n^2}$ . Zbadać zbierność prawie na pewno ciągu

$$W_n = \frac{Z_1 + \dots + Z_n}{Z_1 Z_2 + Z_2 Z_3 + \dots + Z_{n-1} Z_n}$$

#### Twierdzenie 26

Ciąg  $(X_n)_{n \in \mathbb{N}}$  zbiega w  $L^p$  ( $p \geq 1$ ) wtedy i tylko wtedy, gdy  $X_n$  zbiega według prawdopodobieństwa oraz rodzina  $\{|X_n|^p\}_{n \in \mathbb{N}}$  jest jednostajnie całkowalna.

### Twierdzenie 27

Niech  $X_1, X_2, \dots$  będzie ciągiem niezależnych zmiennych losowych o wartościach w przestrzeni Banacha  $F, \|\cdot\|$ . Niech  $S_n = \sum_{i=1}^n X_i$ . Wówczas

$S_n$  zbiega prawie na pewno przy  $n \rightarrow \infty \iff S_n$  zbiega wg. prawdopodobieństwa.

### Twierdzenie 28: Nierówność Lévy’ego-Ottavianiego

Niech  $X_1, X_2, \dots$  będzie ciągiem niezależnych zmiennych losowych o wartościach w przestrzeni Banacha  $F, \|\cdot\|$ . Niech  $S_n = \sum_{i=1}^n X_i$ . Wtedy dla każdego  $j \in \mathbb{N}$  i  $t > 0$  zachodzi

$$\mathbb{P}\left(\max_{k \leq j} \|S_k\| > 3t\right) \leq 3 \max_{k \leq j} P(\|S_k\| > t).$$

### Twierdzenie 29: Kołmogorowa o 2 szeregach

Jeśli  $X_1, X_2, \dots$  są niezależnymi zmiennymi losowymi o wartościach rzeczywistych, o skończonej wariancji takimi, że

$$\sum_{i=1}^{\infty} \text{Var}(X_i) < \infty \text{ oraz } \sum_{i=1}^{\infty} \mathbb{E}X_i \text{ jest zbieżny,}$$

to szereg  $\sum_{i=1}^{\infty} X_n$  zbiega prawie na pewno.

### Twierdzenie 30: Kołmogorowa o 3 szeregach

Niech  $X_1, X_2, \dots$  będą niezależnymi zmiennymi losowymi o wartościach rzeczywistych.

1. Jeśli istnieje  $c > 0$  takie, że szeregi

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}|X_n|^c}{n}, \quad \sum_{n=1}^{\infty} \frac{\text{Var}(X_n)^c}{n}, \quad \sum_{n=1}^{\infty} \frac{\mathbb{P}(|X_n| > c)}{n}$$

są zbieżne, to szereg  $\sum_{n=1}^{\infty} X_n$  jest zbieżny prawie na pewno.

2. Na odwrót: Jeśli szereg  $\sum_{n=1}^{\infty} X_n$  zbiega prawie na pewno, to dla każdego  $c > 0$  szeregi w powyższym wzorze są zbieżne.

### Twierdzenie 31: Mocne prawo wielkich liczb

Niech  $X_1, X_2, \dots$  będą niezależnymi zmiennymi losowymi o tym samym rozkładzie, takim samym jak zmienna losowa  $X$ , o skończonej wartości oczekiwanej  $\mathbb{E}X$ . Wówczas

$$\frac{X_1 + X_2 + \dots + X_n}{n} \xrightarrow{\text{p.n.}} \mathbb{E}X \quad \text{dla } n \rightarrow \infty.$$

### Twierdzenie 32: de’Moivre’a-Laplace’a

Niech  $S_n$  będzie zmienną losową o rozkładzie Bernoulliego  $B(n, p)$ , gdzie  $q = 1 - p$ . Wtedy



dla każdego  $t \in \mathbb{R}$  zachodzi

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{S_n - np}{\sqrt{npq}} \leq t \right) = \Phi(t),$$

gdzie  $\Phi$  jest dystrybucją rozkładu normalnego standardowego.

**Alternatywnie:**

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{S_n - \mathbb{E}S_n}{\sqrt{\text{Var}S_n}} \leq t \right) = \Phi(t),$$

### Twierdzenie 33: Ogólne Centralne Twierdzenie Graniczne

Jeśli  $X_1, X_2, \dots$  są niezależnymi zmiennymi losowymi o tym samym rozkładzie, mającym skończoną i niezerową wariancję, to

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{\sum_{i=1}^n X_i - n\mathbb{E}X_1}{\sqrt{n \text{Var} X_1}} \leq t \right) = \Phi(t).$$

### Twierdzenie 34: Przybliżenie Poissona

Niech  $S_n \sim B(n, p)$ , oznaczmy  $\lambda = np$ . Wtedy dla każdego  $B \in \mathcal{B}(\mathbb{R})$  zachodzi oszacowanie

$$\left| \mathbb{P}(S_n \in B) - \sum_{\substack{k \in B \\ k=0}}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} \right| \leq \frac{\lambda^2}{n}.$$

Czasami równoważnie przyjmujemy

$$\mathbb{P}(S_n \in B) \sim \sum_{\substack{k \in B \\ k=0}}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda}$$

### Przykład 5: Egzamin 2023

**Zadanie 5.** Dane są trzy urny. W pierwszej znajduje się 100 kul, wśród nich jedna zielona i 99 niebieskich, zaś w każdej z pozostałych urn znajduje się 50 kul białych i 50 kul czarnych. Gracz powtarza 900 razy następujący eksperyment: wybiera losowo jedną z urn (każdą z prawdopodobieństwem  $1/3$ ), następnie zwraca ją do urny. Obliczyć w przybliżeniu

- (a) prawdopodobieństwo, że kulę białą wylosowano ponad 310 razy
- (b) prawdopodobieństwo, że kulę zieloną wylosowano co najmniej 3 razy

**Rozwiązanie Zadania 4.**

- (a) Określmy zmienną losową:

$$X_i = \begin{cases} 1 & \text{jeśli } i\text{-ta wylosowana kula będzie biała} \\ 0 & \text{w.p.p.} \end{cases}$$

Zauważmy, że  $\mathbb{P}(X_i = 1) = \frac{1}{3} \cdot 0 + \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{3}$ . Chcemy policzyć  $\mathbb{P} \left( \sum_{i=1}^{900} X_i > 310 \right)$ .

Korzystamy z Tw. dM-L, z  $n = 900, p = \frac{1}{3}, q = 1 - p = \frac{2}{3}$ :

$$\mathbb{P}\left(\sum_{i=1}^{900} X_i > 310\right) = \mathbb{P}\left(\frac{\sum_{i=1}^{900} X_i - 900 \cdot \frac{1}{3}}{\sqrt{900 \cdot \frac{1}{3} \cdot \frac{2}{3}}} > \frac{310 - 900 \cdot \frac{1}{3}}{\sqrt{900 \cdot \frac{1}{3} \cdot \frac{2}{3}}}\right) \sim 1 - \phi\left(\frac{\sqrt{2}}{2}\right)$$

(b) Określmy zmienną losową:

$$Y_i = \begin{cases} 1 & \text{jeśli } i\text{-ta wylosowana kula będzie zielona} \\ 0 & \text{w.p.p.} \end{cases}$$

Zauważmy, że mamy małą ilość zdarzeń oraz znacznie mniejsze prawdopodobieństwo względem poprzedniego podpunktu ( $\mathbb{P}(Y_i = 1) = \frac{1}{300}$ ). Korzystamy więc z przybliżenia Poissona z  $\lambda = np = 900 \cdot \frac{1}{300} = 3$ :

$$\mathbb{P}(Y \geq 3) = 1 - \mathbb{P}(Y \leq 3) = 1 - \sum_{k=0}^2 \mathbb{P}(Y_k) \sim 1 - \sum_{k=0}^2 \frac{3^k}{k!} e^{-3} = 1 - e^{-3} \left(1 + 3 + \frac{3^2}{2!}\right)$$

### Definicja 25: Warunkowa wartość oczekiwana

Niech  $X$  będzie zmienną losową określoną na przestrzeni probabilistycznej  $(\Omega, \mathcal{F}, P)$ , taką że  $E|X| < \infty$ , i niech  $\mathcal{G}$  będzie  $\sigma$ -ciałem,  $\mathcal{G} \subset \mathcal{F}$ . WARUNKOWĄ WARTOŚCIĄ OCZEKIWANĄ  $X$  warunkowo względem  $\mathcal{G}$  nazywamy zmienną losową  $Y$  spełniającą warunki:

1.  $Y$  jest  $\mathcal{G}$ -mierzalna,
2. Dla każdego  $A \in \mathcal{G}$ ,  $E[Y\mathbf{1}_A] = E[X\mathbf{1}_A]$ .

Taką zmienną losową  $Y$  oznaczamy przez  $\mathbb{E}(X|\mathcal{G})$ .

**Własności** gdy  $\mathbb{E}X^2 < \infty$ :

1. Dla dowolnych  $\alpha, \beta \in \mathbb{R}$ ,  $X, Y \in L^2(\Omega, \mathcal{F}, P)$

$$\mathbb{E}(\alpha X + \beta Y|\mathcal{G}) = \alpha \mathbb{E}(X|\mathcal{G}) + \beta \mathbb{E}(Y|\mathcal{G}) \quad P.n.$$

2. Jeśli  $X \geq 0$  p.n., to  $\mathbb{E}(X|\mathcal{G}) \geq 0$  p.n.
3. Jeśli  $X_1 \geq X_2$ , to  $\mathbb{E}(X_1|\mathcal{G}) \geq \mathbb{E}(X_2|\mathcal{G})$  p.n.
4.  $X_n \nearrow X$  p.n. to  $\mathbb{E}(X_n|\mathcal{G}) \nearrow \mathbb{E}(X|\mathcal{G})$

5. Nierówność Jensena

$\varphi : \mathbb{R} \rightarrow \mathbb{R}$  wypukła,  $\mathbb{E}|\varphi(X)| \leq \infty$ . Wtedy

$$\varphi(\mathbb{E}(X|\mathcal{G})) \leq \mathbb{E}(\varphi(X)|\mathcal{G})$$

6. Jeśli  $X$  jest  $\mathcal{G}$ -mierzalne to  $\mathbb{E}(X|\mathcal{G}) = X$  p.n.
7. Jeżeli  $H \subset \mathcal{G}$ , to  $\mathbb{E}(\mathbb{E}(X|\mathcal{G})|H) = \mathbb{E}(X|H)$  p.n.
8. Jeżeli wszystkie zbiory z  $\sigma$ -ciała  $\mathcal{G}$  mają prawdopodobieństwo 0 lub 1 (np.  $\mathcal{G} = \{\emptyset, \Omega\}$ ), to  $\mathbb{E}(X|\mathcal{G}) = \mathbb{E}X$  p.n.
9. Jeżeli  $\sigma$ -ciała  $\sigma(X)$  i  $\mathcal{G}$  są niezależne, to  $\mathbb{E}(X|\mathcal{G}) = \mathbb{E}X$  p.n.
10. Jeżeli  $Y$  jest zmienną losową  $\mathcal{G}$ -mierzalną oraz  $\mathbb{E}|X| < \infty$  i  $\mathbb{E}|XY| < \infty$ , to  $\mathbb{E}(XY|\mathcal{G}) = Y\mathbb{E}(X|\mathcal{G})$  p.n.

**Twierdzenie 35**

Niech  $(X, Y)$  będzie wektorem losowym o wartościach w  $\mathbb{R}^k \times \mathbb{R}^n$  i o rozkładzie ciągłym z gęstością  $g$ . Niech

$$f_{X|Y}(x|y) = \begin{cases} \frac{g(x,y)}{\int_{\mathbb{R}^k} g(x,y)dx} & \text{jeśli } \int_{\mathbb{R}^k} g(x,y)dx > 0 \\ 0 & \text{w.p.p.} \end{cases}$$

Wtedy dla każdej borelowskiej funkcji  $\psi : \mathbb{R}^k \rightarrow \mathbb{R}$ , takiej że  $\mathbb{E}|\psi(X)| < \infty$  zachodzi

$$\mathbb{E}(\psi(X)|Y = y) = \int_{\mathbb{R}^k} \psi(x) f_{X|Y}(x|y) dx$$

Równoważnie, używając innego zapisu:

$$\mathbb{E}(\psi(X)|Y) = \int_{\mathbb{R}^k} \psi(x) f_{X|Y}(x|Y) dx = \frac{\int_{\mathbb{R}^k} \psi(x) g(x, Y) dx}{\int_{\mathbb{R}^k} g(x, Y) dx} \quad \text{p.n.}$$