

# Rachunek Prawdopodobieństwa II

Data ostatniej aktualizacji: 3 grudnia 2024

## Krótki Wstęp

Uważny czytelnik zauważy, że poniższe notatki przypominają niezwykle dydaktyczne prace [dr Arkadiusza Męcla](#), które również gorąco polecam.

*Link do omówienia pewniaków na egzamin znajduje się [tutaj](#)*

## 1 Zbieżność według rozkładu

### Definicja 1.1: Zbieżność rozkładów

Niech  $\mu, \mu_1, \mu_2, \dots$  będą rozkładami prawdopodobieństwa na  $(E, \rho)$ . Mówimy, że ciąg  $(\mu_n)$  zbiega do  $\mu$ :

- (a) w sensie całkowitego wahania, jeżeli  $\lim_{n \rightarrow \infty} \|\mu_n - \mu\|_{TV} = 0$ .
- (b) silnie, jeżeli  $\forall B \in \mathcal{B}(E) \lim_{n \rightarrow \infty} \mu_n(B) = \mu(B)$ .

### Definicja 1.2: Słaba zbieżność

Niech  $\mu, \mu_1, \mu_2, \dots$  będą rozkładami prawdopodobieństwa na przestrzeni  $(E, \rho)$ . Mówimy, że ciąg  $(\mu_n)$  ZBIEGA SŁABO DO ROZKŁADU  $\mu$  (ozn.  $\mu_n \Rightarrow \mu$ ), jeżeli dla każdej funkcji  $f \in C(E)$  zachodzi

$$\lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu.$$

Alternatywnie:

$$\lim_{n \rightarrow \infty} \mathbb{E}f(X_n) = \mathbb{E}f(X), \quad \forall f \in C(E).$$

*$C(E)$ - ciągłe i ograniczone*

### Twierdzenie 1.1: Jedyność rozkładu

Założmy, że  $\mu$  i  $\nu$  są rozkładami prawdopodobieństwa na  $(E, \rho)$  takimi, że dla każdej funkcji jednostajnie ciągłej i ograniczonej  $f : E \rightarrow \mathbb{R}$  zachodzi

$$\int f d\mu = \int f d\nu.$$

Wtedy  $\mu \equiv \nu$ .

### Twierdzenie 1.2

Niech  $X, X_1, X_2, \dots$  będą zmiennymi losowymi o wartościach w  $(E, \rho)$  (mogą być określone na różnych przestrzeniach probabilistycznych!) o rozkładach  $\mu, \mu_1, \mu_2, \dots$ , odpowiednio. Mówimy, że ciąg  $(X_n)$  zbiega według rozkładu do  $X$ , jeżeli  $\mu_n \Rightarrow \mu$ . Piszemy

$$X_n \xrightarrow{D} X$$

### Twierdzenie 1.3: Charakteryzacja zbieżności według rozkładu

Niech  $\mu, \mu_1, \mu_2, \dots$  będą rozkładami prawdopodobieństwa na przestrzeni metrycznej  $(E, \rho)$ . Następujące warunki są równoważne:

1.  $\mu_n \Rightarrow \mu$ .

2.

$$\forall f \in C_{\text{jedn}}(E) \quad \lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu$$

Alternatywnie:

$$\mathbb{E}f(X_n) \rightarrow \mathbb{E}f(X)$$

3. Dla każdego zbioru domkniętego  $F \subset E$  zachodzi

$$\limsup_{n \rightarrow \infty} \mu_n(F) \leq \mu(F)$$

4. Dla każdego zbioru otwartego  $G \subset E$  zachodzi

$$\liminf_{n \rightarrow \infty} \mu_n(G) \geq \mu(G)$$

5. Dla każdego zbioru  $A \in \mathcal{B}(E)$ , takiego że  $\mu(\partial A) = 0$  (gdzie  $\partial A = A \setminus \text{int}(A)$  — brzeg zbioru  $A$ ), zachodzi

$$\lim_{n \rightarrow \infty} \mu_n(A) = \mu(A)$$

### Fakt 1.1

Jeśli dla każdej  $f$  - ograniczonej i ciągłej zachodzi

$$\mathbb{E}f(X) = \mathbb{E}f(Y)$$

to  $X$  i  $Y$  mają ten sam rozkład

### Twierdzenie 1.4

Niech  $X, X_1, Y_1, X_2, Y_2, \dots$  będą zmiennymi losowymi o wartościach w ośrodkowej przestrzeni metrycznej  $(E, \rho)$ , przy czym zakładamy, że ciągi zmiennych losowych  $(X_n)_n$  i  $(Y_n)_n$  są określone na tej samej przestrzeni probabilistycznej. Jeżeli

$$Y_n \xrightarrow{D} X \text{ oraz } \rho(X_n, Y_n) \xrightarrow{P} 0$$

to

$$X_n \xrightarrow{D} X$$

### Twierdzenie 1.5

Jeżeli  $X, X_1, X_2, \dots$  są zmiennymi losowymi określonymi na tej samej przestrzeni probabilistycznej o wartościach w ośrodkowej przestrzeni metrycznej  $(E, \rho)$  takimi, że  $X_n$  zbiega do  $X$  według prawdopodobieństwa, to  $X_n \Rightarrow X$ .

### Twierdzenie 1.6: Zbieżność rozkładów a zbieżność dystrybuant

Niech  $\mu, \mu_1, \mu_2, \dots$  będą rozkładami prawdopodobieństwa na  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  o dystrybuantach  $F, F_1, F_2, \dots$ , odpowiednio.

NWSR

- $\mu_n \Rightarrow \mu$
- $\lim_{n \rightarrow \infty} F_n(t) = F(t)$  dla każdego  $t$  będącego punktem ciągłości dystrybuanty granicznej  $F$ .

### Przykład 1.1: Kolokwium 2012

**Zadanie 1.** Zmienne  $X_n$  i  $Y_n$  są określone na wspólnej przestrzeni probabilistycznej, przy czym zmienna  $X_n$  ma gęstość

$$f_{X_n}(x) = \frac{5}{2n^5} x^4 \mathbf{1}_{\{|x| \leq \frac{1}{n}\}},$$

a zmienne  $Y_n$  spełniają warunek

$$\mathbb{P}(Y_n = \frac{k}{n}) = 1 - e^{-\frac{5}{n}} e^{-\frac{5k}{n}}, \quad k = 0, 1, \dots$$

Czy wynika stąd, że ciąg  $X_n + Y_n$  jest zbieżny według rozkładu? Jeśli tak, to do jakiej granicy?

**Wskazówka:** Może się przydać fakt, że

$$\lim_{x \rightarrow 0} \frac{1}{x} (1 - e^{-x}) = 1.$$

### Definicja 1.3: Ciasność rodziny rozkładów

Niech  $\mathcal{P}$  będzie pewną rodziną rozkładów prawdopodobieństwa na przestrzeni metrycznej  $(E, \rho)$ . Mówimy, że  $\mathcal{P}$  jest **CIASNA** (albo: jędrna, ang. *tight*), jeżeli dla każdego  $\varepsilon > 0$  istnieje zbiór zwarty  $K \subset E$  taki, że

$$\forall_{\mu \in \mathcal{P}} \mu(K) \geq 1 - \varepsilon$$

### Twierdzenie 1.7

Niech  $\{X_\alpha : \alpha \in \Lambda\}$  będzie rodziną zmiennych losowych dla których istnieje  $\delta > 0$  taka, że

$$\sup_{\alpha} \mathbb{E}|X_\alpha| = M < \infty$$

Wtedy rodzina  $\{\mu_\alpha : \alpha \in \Lambda\}$  jest ciasna.

### Definicja 1.4: Warunkowa zwartość rodziny rozkładów

Niech  $(E, \rho)$  będzie przestrzenią metryczną. Mówimy, że rodzina  $\mathcal{P}$  rozkładów prawdopodobieństwa na  $(E, \mathcal{B}(E))$  jest **WARUNKOWO ZWARTA**, jeżeli z każdego ciągu  $(\mu_n)$ , gdzie  $\mu_n \in \mathcal{P}$ , można wybrać podciąg słabo zbieżny do pewnej miary probabilistycznej  $\mu$  na  $(E, \mathcal{B}(E))$  (ale niekoniecznie  $\mu \in \mathcal{P}$ ).

### Twierdzenie 1.8: Twierdzenie Prochorowa

Niech  $(E, \rho)$  będzie przestrzenią metryczną, a  $\mathcal{P}$  pewną rodziną rozkładów na  $(E, \mathcal{B}(E))$ .

- Jeżeli  $\mathcal{P}$  jest ciasna, to jest warunkowo zwarta.
- Na odwrót: Jeżeli  $(E, \rho)$  jest przestrzenią polską (metryczną, ośrodkową i zupełną) i  $\mathcal{P}$  jest warunkowo zwarta, to jest ciasna.

$\mathcal{P}$  jest ciasna  $\implies \mathcal{P}$  jest warunkowo zwarta

$\left. \begin{array}{l} \mathcal{P} \text{ jest warunkowo zwarta} \\ (E, \rho) \text{ jest polska} \end{array} \right\} \implies \mathcal{P} \text{ jest ciasna}$

## 2 Funkcje Charakterystyczne

### Definicja 2.1: Wartość oczekiwana zmiennej zespolonej

Niech  $Z$  będzie zmienną losową o wartościach w  $\mathbb{C}$ , taką że  $\operatorname{Re} Z$  i  $\operatorname{Im} Z$  mają wartość oczekiwaną. Definiujemy

$$\mathbb{E}Z = \mathbb{E}\operatorname{Re} Z + i\mathbb{E}\operatorname{Im} Z.$$

### Definicja 2.2: Funkcja charakterystyczna

- (a) Niech  $\mu$  będzie miarą probabilistyczną na  $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ . Funkcją charakterystyczną  $\mu$  nazywamy funkcję  $\varphi : \mathbb{R}^d \rightarrow \mathbb{C}$  daną wzorem:

$$\varphi_\mu(t) = \int_{\mathbb{R}^d} e^{i\langle t, x \rangle} \mu(dx), \quad t \in \mathbb{R}^d,$$

gdzie  $\langle \cdot, \cdot \rangle$  jest iloczynem skalarnym w  $\mathbb{R}^d$ .

- (b) Niech  $X$  będzie wektorem losowym o wartościach w  $\mathbb{R}^d$  i rozkładzie  $\mu_X$ . Funkcję  $\varphi_X := \varphi_{\mu_X}$  nazywamy FUNKCJĄ CHARAKTERYSTYCZNĄ WEKTORA LOSOWEGO  $X$ .

$\varphi_\mu$  jest  
transformatą  
Fouriera miary  
 $\mu$

### Twierdzenie 2.1: Własności funkcji charakterystycznej

Niech  $X$  będzie wektorem losowym o wartościach w  $\mathbb{R}^d$ , a  $\varphi_X$  jego funkcją charakterystyczną. Wtedy:

1.  $\varphi_X(0) = 1$ .
2.  $|\varphi_X(t)| \leq 1$ .
3.  $\varphi_X(-t) = \overline{\varphi_X(t)}$ .
4. Jeżeli rozkład  $X$  jest symetryczny, tj.  $-X \sim X$ , to  $\varphi_X$  przyjmuje wartości rzeczywiste.
5.  $\varphi_X$  jest jednostajnie ciągła w  $\mathbb{R}^d$ .
6. Jeżeli  $A$  jest macierzą  $n \times d$  i  $b \in \mathbb{R}^n$ , to

$$\varphi_{AX+b}(s) = e^{i\langle s, b \rangle} \varphi_X(A^\top s), \quad s \in \mathbb{R}^n.$$

7. Jeżeli  $d = 1$  (tj.  $X$  jest zmienną losową o wartościach rzeczywistych) oraz  $\mathbb{E}|X|^k < \infty$  dla pewnego  $k \in \mathbb{N}$ , to  $\varphi_X$  jest  $k$ -krotnie różniczkowalna,

$$\varphi_X^{(k)}(t) = i^k \mathbb{E} \left[ e^{itX} X^k \right],$$

oraz  $\varphi_X^{(k)}$  jest jednostajnie ciągła. Ponadto  $\varphi_X^{(k)}(0) = i^k \mathbb{E} X^k$ .

8. Na odwrót, jeżeli  $X$  jest zmienną losową o wartościach rzeczywistych i  $\varphi_X^{(k)}(0)$  istnieje dla pewnego parzystego  $k$ , to  $\mathbb{E}|X|^k < \infty$ .
9. Jeżeli  $X_1, X_2, \dots, X_n$  są niezależnymi wektorami losowymi o wartościach w  $\mathbb{R}^d$ , to

$$\varphi_{X_1 + \dots + X_n}(t) = \prod_{k=1}^n \varphi_{X_k}(t).$$

10. Jeżeli  $X_1, X_2, \dots, X_n$  są niezależne, to

$$\varphi_{(X_1, \dots, X_n)}(t_1, \dots, t_n) = \prod_{k=1}^n \varphi_{X_k}(t_k).$$

11. Funkcja  $\varphi_X$  jest dodatnio określona, tj.  $\forall n \forall t_1, \dots, t_n \in \mathbb{R}^d \forall z_1, \dots, z_n \in \mathbb{C}$  zachodzi:

$$\sum_{k,j=1}^n z_k \varphi_X(t_k - t_j) \overline{z_j} \geq 0.$$

12. Jeśli  $\varphi_i$  są funkcjami charakterystycznymi i  $\sum p_i = 1$ ,  $p_i > 0$  to kombinacja wypukła  $\sum p_i \varphi_i$  również jest funkcją charakterystyczną.

| Rozkład                               | Gęstość  | Funkcja charakterystyczna                                       |
|---------------------------------------|--|---|
| Normalny $\mathcal{N}(\mu, \sigma^2)$ | $g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$       | $\varphi(t) = \exp\left(it\mu - \frac{1}{2}\sigma^2 t^2\right)$ |
| cv Jednostajny $U(a, b)$              | $g(x) = \frac{1}{b-a}, \quad a \leq x \leq b$  | $\varphi(t) = \frac{e^{itb} - e^{ita}}{it(b-a)}$                |
| Exponentialny $\text{Exp}(\lambda)$   | $g(x) = \lambda e^{-\lambda x}, \quad x \geq 0$  | $\varphi(t) = \frac{\lambda}{\lambda - it}$                     |
| Gamma $\Gamma(\alpha, \beta)$         | $g(x) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha)\beta^\alpha}$                      | $\varphi(t) = (1 - it\beta)^{-\alpha}$                          |
| Cauchy $\mathcal{C}(\mu, \gamma)$     | $g(x) = \frac{1}{\pi\gamma} \left[ 1 + \left( \frac{x-\mu}{\gamma} \right)^2 \right]^{-1}$ | $\varphi(t) = \exp(it\mu - \gamma t )$                          |
| Poissona $\text{Poisson}(\lambda)$    | $g(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x \in \mathbb{N}_0$                       | $\varphi(t) = \exp(\lambda(e^{it} - 1))$                        |

Tabela 1: Podstawowe gęstości i funkcje charakterystyczne

### Twierdzenie 2.2: O jednoznaczności

Jeżeli dla pewnych miar probabilistycznych  $\mu$  i  $\nu$  na  $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$  zachodzi  $\varphi_\mu(t) = \varphi_\nu(t)$  dla każdego  $t \in \mathbb{R}^d$ , to  $\mu \equiv \nu$ .

### Wniosek 2.1

Zmienne losowe  $X_1, \dots, X_d$  są niezależne wtedy i tylko wtedy, gdy funkcja charakterystyczna wektora losowego  $X = (X_1, \dots, X_d)$  ma postać

$$\varphi_X(t) = \prod_{j=1}^d \varphi_{X_j}(t_j), \quad t = (t_1, \dots, t_d).$$

### Przykład 2.1: Kolokwium 2016

**Zadanie 2.** Zmienna losowa  $X$  ma funkcję charakterystyczną  $\varphi_X$

- i) Wykaż, że istnieje zmienna losowa  $Y$ , której funkcja charakterystyczna ma postać

$$\varphi_Y = \frac{1}{5 - 4\varphi_X}$$

- ii) Zmienna losowa  $X$  ma wartości w przedziale  $[0, 1]$ . Czy z tego wynika, że zmienna losowa  $Y$  jest nieujemna? Czy wynika, że  $Y$  jest ograniczona?

### Twierdzenie 2.3

Niech  $Q$  będzie macierzą  $d \times d$ , symetryczną i nieujemnie określoną,  $a \in \mathbb{R}^d$  oraz niech  $Y$  będzie zmienną losową o rozkładzie normalnym  $N(a, Q)$ . Ponadto załóżmy, że  $B$  jest macierzą o  $n$  wierszach i  $d$  kolumnach oraz  $b \in \mathbb{R}^n$ . Niech  $Z$  będzie wektorem losowym zdefiniowanym jako  $Z = BY + b$ . Wtedy  $Z \sim N(Ba + b, BQB^T)$ .

**Uwaga:** W szczególności, jeżeli  $Y = (Y_1, \dots, Y_d)$  ma rozkład Gaussa, to dla dowolnych  $j_1, \dots, j_k \in \{1, \dots, d\}$  wektor  $(Y_{j_1}, \dots, Y_{j_k})$  ma rozkład Gaussa.

### Twierdzenie 2.4

Istnieje stała  $C > 0$  taka, że dla każdego rozkładu probabilistycznego  $\mu$  na  $\mathbb{R}$  o funkcji charakterystycznej  $\varphi$  zachodzi

$$\mu(\{x : |x| \geq K\}) \leq \frac{C}{K} \int_{-K}^K (1 - \varphi(s)) ds, \quad K > 0.$$

### Twierdzenie 2.5: (Twierdzenie Lévy'ego-Craméra)

Niech  $(\mu_n)_n$  będzie ciągiem rozkładów probabilistycznych na  $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$  o funkcjach charakterystycznych  $(\varphi_n)$ , odpowiednio. Jeżeli

$$\lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t) \quad \text{dla każdego } t \in \mathbb{R}^d$$

oraz funkcja  $\varphi$  jest ciągła w zerze, to  $\varphi$  jest funkcją charakterystyczną pewnego rozkładu probabilistycznego  $\mu$  oraz  $\mu_n \Rightarrow \mu$ .

**Uwaga.** Na odwrót: jeżeli  $\mu_n \Rightarrow \mu$ , to  $\varphi_n(t) \rightarrow \varphi_\mu(t)$ .

### Twierdzenie 2.6: (Tożsamość Parsevala)

Niech  $\varphi$  i  $\psi$  będą funkcjami charakterystycznymi rozkładów  $\mu$  i  $\nu$  na  $(\mathbb{R}^d, B(\mathbb{R}^d))$ . Wtedy

$$\int_{\mathbb{R}^d} e^{-i\langle s, t \rangle} \varphi(s) \nu(ds) = \int_{\mathbb{R}^d} \psi(x - t) \mu(dx).$$

### Twierdzenie 2.7: (Odwrotna transformata Fouriera)

Rozkład prawdopodobieństwa  $\mu$  na  $(\mathbb{R}^d, B(\mathbb{R}^d))$ , który ma całkowalną funkcję charakterystyczną  $\varphi$ , ma także ograniczoną i ciągłą gęstość  $f$  daną wzorem

$$f(x) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{-i\langle s, x \rangle} \varphi(s) ds.$$

### Twierdzenie 2.8

Ciągła, ograniczona i całkowalna funkcja  $\varphi : \mathbb{R}^d \rightarrow \mathbb{C}$  jest funkcją charakterystyczną pewnego rozkładu prawdopodobieństwa wtedy i tylko wtedy, gdy  $\varphi(0) = 1$  oraz funkcja  $f$  zdefiniowana w Odwrotnej Transformacie Fouriera jest nieujemna. Ponadto, wówczas  $f$  jest gęstością rozkładu o funkcji charakterystycznej  $\varphi$ .

### Twierdzenie 2.9: (Twierdzenie Bochnera)

Każda funkcja  $\varphi : \mathbb{R}^d \rightarrow \mathbb{R}$  ciągła, dodatnio określona i taka, że  $\varphi(0) = 1$ , jest funkcją charakterystyczną pewnej miary probabilistycznej na  $\mathbb{R}^d$ .

*"Podobno ktoś go kiedyś użył w praktyce" - dr Rafał Meller*

## 3 Centralne Twierdzenie Graniczne

### Twierdzenie 3.1: Twierdzenie Lindeberga

Niech  $(X_{n,k})$ ,  $n = 1, 2, \dots$ ,  $k = 1, 2, \dots, r_n$  będzie tablicą zmiennych losowych (o wartościach rzeczywistych) o skończonej wariancji. Załóżmy, że dla każdego  $n$  zmienne losowe  $X_{n,1}, \dots, X_{n,r_n}$  są niezależne,  $\mathbb{E}X_{n,k} = 0$  dla  $k = 1, 2, \dots, r_n$  oraz

$$\sum_{k=1}^{r_n} \text{Var} X_{n,k} \rightarrow 1 \quad \text{gdy } n \rightarrow \infty.$$

Ponadto załóżmy, że zachodzi WARUNEK LINDEBERGA:

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \mathbb{E} \left[ X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon\}} \right] = 0.$$

Wtedy

$$\sum_{k=1}^{r_n} X_{n,k} \xrightarrow{D} \mathcal{N}(0, 1) \quad \text{gdy } n \rightarrow \infty.$$

### Stwierdzenie 3.1

Jeżeli zachodzi Twierdzenie Lindeberga, to:

- (a)  $\max_{1 \leq k \leq r_n} |X_{n,k}| \xrightarrow{\mathbb{P}} 0 \quad \text{gdy } n \rightarrow \infty,$
- (b)  $\lim_{n \rightarrow \infty} \max_{1 \leq k \leq r_n} \mathbb{E} X_{n,k}^2 = 0.$



Punkt (a) oznacza, że wkład każdego ze składników w sumę jest mały.  
 Punkt (b) mówi, że wariancja każdego ze składników jest mała w porównaniu z sumą. W szczególności musi zachodzić  $r_n \rightarrow \infty$ .

### Twierdzenie 3.2: Centralne Twierdzenie Graniczne

Niech  $X_1, X_2, \dots$  będą niezależnymi zmiennymi losowymi o tym samym rozkładzie i skończonej, niezerowej wariancji. Oznaczmy  $m = \mathbb{E}X_k$ ,  $\sigma^2 = \text{Var}X_k$ . Wtedy

$$\frac{\sum_{k=1}^n X_k - nm}{\sqrt{n}\sigma} \xrightarrow{D} \mathcal{N}(0, 1) \quad \text{gdy } n \rightarrow \infty.$$

### Wniosek 3.1

Niech  $X_{n,k}$ -schemat tablicowy takie że:

- dla każdego  $n$   $X_{1,n}, \dots, X_{n,n}$  są niezależne,  $S_n = \sum_{k=1}^n X_{k,n}$
- $\mathbb{E}S_n \xrightarrow{n \rightarrow \infty} \mu$
- $\text{Var}S_n \xrightarrow{n \rightarrow \infty} \sigma^2$
- zmienne  $X_{n,k} - \mathbb{E}X_{n,k}$  spełniają warunek Lindeberga

Wtedy

$$S_n \xrightarrow{\mathcal{D}} \mathcal{N}(\mu, \sigma^2)$$

### Twierdzenie 3.3: Warunek Lapunowa

Niech  $(X_{n,k})$ ,  $n = 1, 2, \dots$ ,  $k = 1, 2, \dots, r_n$  będzie tablicą zmiennych losowych (o wartościach rzeczywistych) o skończonej wariancji. Przyjmijmy, że  $\mathbb{E}X_{n,k} = 0$ . WARUNEK LAPUNOWA zachodzi, jeśli istnieje  $\delta > 0$  takie że zachodzi :

$$\lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \mathbb{E}|X_{n,k}|^{2+\delta} = 0.$$

Wtedy spełniony jest warunek Lindeberga.

### Twierdzenie 3.4: Ogólne Centralne Twierdzenie Graniczne

Niech  $(X_{n,k})$ ,  $n = 1, 2, \dots$ ,  $k = 1, 2, \dots, r_n$  będzie tablicą zmiennych losowych (o wartościach rzeczywistych) o skończonej wariancji. Załóżmy, że dla każdego  $n$  zmienne losowe  $X_{n,1}, \dots, X_{n,r_n}$  są niezależne oraz

$$\lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \mathbb{E}X_{n,k} = m, \quad \lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \text{Var}X_{n,k} = \sigma^2.$$

Ponadto załóżmy, że zachodzi warunek Lindeberga:

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \mathbb{E} \left( |X_{n,k} - \mathbb{E}X_{n,k}|^2 \mathbf{1}_{\{|X_{n,k} - \mathbb{E}X_{n,k}| > \varepsilon\}} \right) = 0.$$

Wtedy

$$\sum_{k=1}^{r_n} X_{n,k} \xrightarrow{D} N(m, \sigma^2) \quad \text{gdy } n \rightarrow \infty.$$

### Przykład 3.1: Kolokwium 2023 - Warunek Lapunowa

**Zadanie 3.** Rozważmy ciąg niezależnych zmiennych losowych  $X_1, X_2, \dots$ , taki że zmienna  $X_k$  ma rozkład wykładniczy z parametrem  $\frac{1}{k}$ . Niech  $S_n = X_1 + \dots + X_n$ . Czy ciąg zmiennych losowych

$$Z_n = \frac{S_n - \mathbb{E}S_n}{\sqrt{\text{Var}S_n}}$$

jest zbieżny według rozkładu? Jeśli tak – wyznaczyć granicę, w przeciwnym przypadku – uzasadnić brak zbieżności.

**Rozwiązanie Zadania 1.** Wiemy, że jeśli  $X \sim \text{Exp}(\lambda)$ , to  $\mathbb{E}X^k = \frac{k!}{\lambda^k}$ , więc

$$\mathbb{E}X_k = k \quad \text{Var}S_n = \sum_{k=1}^n \text{Var}X_k = \sum_{k=1}^n \left( \frac{2!}{k^2} - \left( \frac{1}{k} \right)^2 \right) = \sum_{k=1}^n \frac{1}{k^2} = \frac{n(n+1)(2n+1)}{6}$$

Chcemy skorzystać z warunku Lapunowa, czyli znaleźć takie  $\delta > 0$ , że

$$\lim_{n \rightarrow \infty} \frac{1}{s_n^{2+\delta}} \sum_{k=1}^{r_n} \mathbb{E}|X_{n,k} - \mathbb{E}X_{n,k}|^{2+\delta} = 0, \quad s_n = \sqrt{\text{Var}S_n}$$

Weźmy  $\delta = 1$ . Wtedy:

$$\sum_{k=1}^n \mathbb{E}|X_k - \mathbb{E}X_k|^3 = \sum_{k=1}^n \mathbb{E} \left[ X_k^3 - 3X_k^2 \mathbb{E}X_k + 3X_k(\mathbb{E}X_k)^2 - (\mathbb{E}X_k)^3 \right].$$

Zauważmy teraz, że każdy z wyrazów w powyższej sumie jest równy co najwyżej  $Ck^3$  dla pewnej stałej  $C > 0$ , w związku z czym

$$\sum_{k=1}^n \mathbb{E}|X_k - \mathbb{E}X_k|^3 \leq C \sum_{k=1}^n k^3 = O(n^4) \quad \text{przy } n \rightarrow \infty,$$

gdzie skorzystaliśmy z elementarnych własności sum typu  $\sum_{k=1}^n k^\alpha$ .

Jednocześnie

$$s_n^3 = (\text{Var}S_n)^{3/2} = \left( \frac{n(n+1)(2n+1)}{6} \right)^{3/2} = \Theta(n^{9/2}).$$

Stąd mamy

$$\frac{1}{s_n^3} \sum_{k=1}^n \mathbb{E}|X_k - \mathbb{E}X_k|^3 = O(n^{4-9/2}) = O(n^{-1/2}) \rightarrow 0 \quad \text{przy } n \rightarrow \infty,$$

co chcieliśmy pokazać.

**Uwaga:**

Wariancja jest sumą poszczególnych wariancji ponieważ  $X_k$  są niezależne

### Twierdzenie 3.5

Przy powyższych założeniach dla każdego  $t \in \mathbb{R}$  zachodzi

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \sum_{k=1}^{r_n} X_{n,k} \leq t \right) = \Phi(t),$$

gdzie  $\Phi$  oznacza dystrybucję rozkładu normalnego standardowego. Ponadto, zbieżność jest jednostajna względem  $t$ .

### Twierdzenie 3.6: Berry-Esseen

Niech  $X_1, X_2, \dots$  będą niezależnymi zmiennymi losowymi o tym samym rozkładzie. Założymy ponadto, że  $\mathbb{E}|X_k|^3 < \infty$  oraz  $\text{Var}X_k = \sigma^2 > 0$ , i oznaczmy  $m = \mathbb{E}X_k$ ,  $\sigma^2 = \text{Var}X_k$ . Wtedy

$$\left| \mathbb{P} \left( \frac{\sum_{k=1}^n X_k - nm}{\sqrt{n\sigma^2}} \leq t \right) - \Phi(t) \right| \leq C \frac{\mathbb{E}|X_1 - \mathbb{E}X_1|^3}{\sigma^3 \sqrt{n}},$$

gdzie  $\Phi$  jest dystrybucją rozkładu  $N(0, 1)$ , a  $C$  pewną dodatnią stałą taką, że  $\frac{1}{\sqrt{2\pi}} \leq C < 0.8$ .

## 4 Martyngały

### Definicja 4.1: Filtracja

FILTRACJĄ nazywamy rodzinę  $\sigma$ -ciał  $(\mathcal{F}_t)_{t \in T}$ ,  $\mathcal{F}_t \subset \mathcal{F}$ , taką, że dla dowolnych  $t_1 \leq t_2$ ,  $t_1, t_2 \in T$ , zachodzi zawieranie  $\mathcal{F}_{t_1} \subset \mathcal{F}_{t_2}$ .

### Definicja 4.2: Proces adaptowany do filtracji

Niech  $(X_t)_{t \in T}$  będzie rodziną zmiennych losowych określonych na pewnej przestrzeni probabilistycznej  $(\Omega, \mathcal{F}, \mathbb{P})$ , a  $(\mathcal{F}_t)_{t \in T}$  filtracją. Mówimy, że proces  $(X_t)_{t \in T}$  jest adaptowany do  $(\mathcal{F}_t)_{t \in T}$ , jeżeli dla każdego  $t \in T$  zmienna  $X_t$  jest  $\mathcal{F}_t$ -mierzalna.

### Definicja 4.3: Filtracja naturalna

Niech  $(X_t)_{t \in T}$  będzie rodziną zmiennych losowych określonych na pewnej przestrzeni probabilistycznej  $(\Omega, \mathcal{F}, \mathbb{P})$ . Dla każdego  $t \in T$  kładziemy

$$\mathcal{F}_t = \sigma(X_s : s \leq t, s \in T)$$

tj. najmniejsze  $\sigma$ -ciało, względem którego mierzalne są wszystkie zmienne losowe  $X_s$  dla  $s \leq t$ . Rodzina  $(\mathcal{F}_t)_{t \in T}$  jest filtracją. Tak zdefiniowaną filtrację nazywamy FILTRACJĄ NATURALNĄ dla procesu  $(X_t)_{t \in T}$ .

### Definicja 4.4: Moment zatrzymania

Niech  $(\mathcal{F}_t)_{t \in T}$  będzie pewną ustaloną filtracją. Funkcję  $\tau : \Omega \rightarrow T \cup \{+\infty\}$  nazywamy MOMENTEM ZATRZYMANIA względem filtracji  $(\mathcal{F}_t)_{t \in T}$ , jeżeli dla każdego  $t \in T$  zachodzi  $\{\tau \leq t\} \in \mathcal{F}_t$ .

### Twierdzenie 4.1: Moment zatrzymania

Niech  $(\mathcal{F}_n)_{n \in T}$  będzie filtracją.  
NWSR

- Funkcja  $\tau : \Omega \rightarrow T \cup \{+\infty\}$  jest momentem zatrzymania
- Dla każdego  $n \in T$  zachodzi  $\{\tau = n\} \in \mathcal{F}_n$ .

### Twierdzenie 4.2: Operacje na momentach zatrzymania

Niech  $\tau, \sigma, \tau_1, \tau_2, \dots$  będą momentami zatrzymania względem pewnej filtracji  $(\mathcal{F}_n)_{n=0}^\infty$ . Wtedy:

$$\tau \wedge \sigma \quad \tau \vee \sigma \quad \tau + \sigma \quad \sup_n \tau_n \quad \inf_n \tau_n$$

są momentami zatrzymania.

**Ozn.**  $a \wedge b := \min(a, b)$ ,  $a \vee b := \max(a, b)$

**Definicja 4.5: Klasa zdarzeń związanych z momentem zatrzymania**

Niech  $\tau$  będzie momentem zatrzymania względem pewnej filtracji  $(\mathcal{F}_t)_{t \in T}$ . Przez  $\mathcal{F}_\tau$  oznaczamy klasę takich zdarzeń  $A \in \mathcal{F}$ , że

$$A \cap \{\tau \leq t\} \in \mathcal{F}_t \quad \forall_{t \in T}$$

$\mathcal{F}_\tau$  zawiera więc zdarzenia, o których możemy powiedzieć, czy zaszły czy nie, jeżeli obserwujemy doświadczenie do chwili  $\tau$ .

**Stwierdzenie 4.1: Właściwości klasy  $\mathcal{F}_\tau$** 

Niech  $\tau$  będzie momentem zatrzymania względem filtracji  $(\mathcal{F}_t)_{t \in T}$ . Wówczas:

1.  $\mathcal{F}_\tau$  jest  $\sigma$ -ciałem,
2.  $A \in \mathcal{F}_\tau$  wtedy i tylko wtedy, gdy dla każdego  $n \in T$  zachodzi  $A \cap \{\tau = n\} \in \mathcal{F}_n$ ,
3. Jeżeli  $\tau \equiv k$  dla pewnego  $k \in T$ , to  $\mathcal{F}_\tau = \mathcal{F}_k$ ,
4. Jeżeli  $\tau_1$  i  $\tau_2$  są momentami zatrzymania takimi, że  $\tau_1 \leq \tau_2$ , to  $\mathcal{F}_{\tau_1} \subset \mathcal{F}_{\tau_2}$ ,
5.  $\tau$  jest  $\mathcal{F}_\tau$ -mierzalne,
6. Jeżeli  $(X_t)_{t \in T}$  jest ciągiem zmiennych losowych adaptowanych do  $(\mathcal{F}_t)_{t \in T}$ , to  $X_\tau$  jest  $\mathcal{F}_\tau$ -mierzalne na zbiorze  $\{\tau < \infty\}$ .

(Uwaga:  $X_\tau(\omega) = X_{\tau(\omega)}(\omega)$ ).